Experiment 1

MIL-Attention + Dual Fusion
MLP + Hierarchical Classification

Regensburg Pediatric Appendicitis Dataset

578
pasien

53
fitur tabular

36
skenario

Termasuk kontrol MIL-Attention dan MLP yang benar-benar dilatih independen.

Rancangan yang sedang dilaporkan

Data dan target

578 pasien / 1.739 panel

3 kelas hierarkis

Diagnosis dan severity

Unit evaluasi: pasien

Eksperimen utama

36 trial serial

Split dan seed tetap

Pilih via validation F1

Uji pemenang S26

Kontrol tambahan

MIL-Attention mandiri

MLP mandiri

Parameter S26 tetap

Keduanya diuji

Bahan penilaian peneliti; tidak menetapkan klaim keberhasilan atau keputusan eksperimen berikutnya.

Posisi metode terhadap paper referensi

Komponen	Paper multimodal [1]	Experiment 1
Input klinis	53 fitur / TabNet	53 fitur / MLP
Citra	ResNet18, menyebut ROI	ResNet18, panel global
Agregasi / fusion	Cross-attention	Dual MIL-attention + concat
Target	Diagnosis biner	3 kelas hierarkis
Split	80:20 per pasien	64:16:20 per pasien

Baseline dengan unsur referensi; bukan reproduksi identik. Mean/LSTM [2] belum diuji ulang di run aktif.

53 fitur: representasi dan missingness

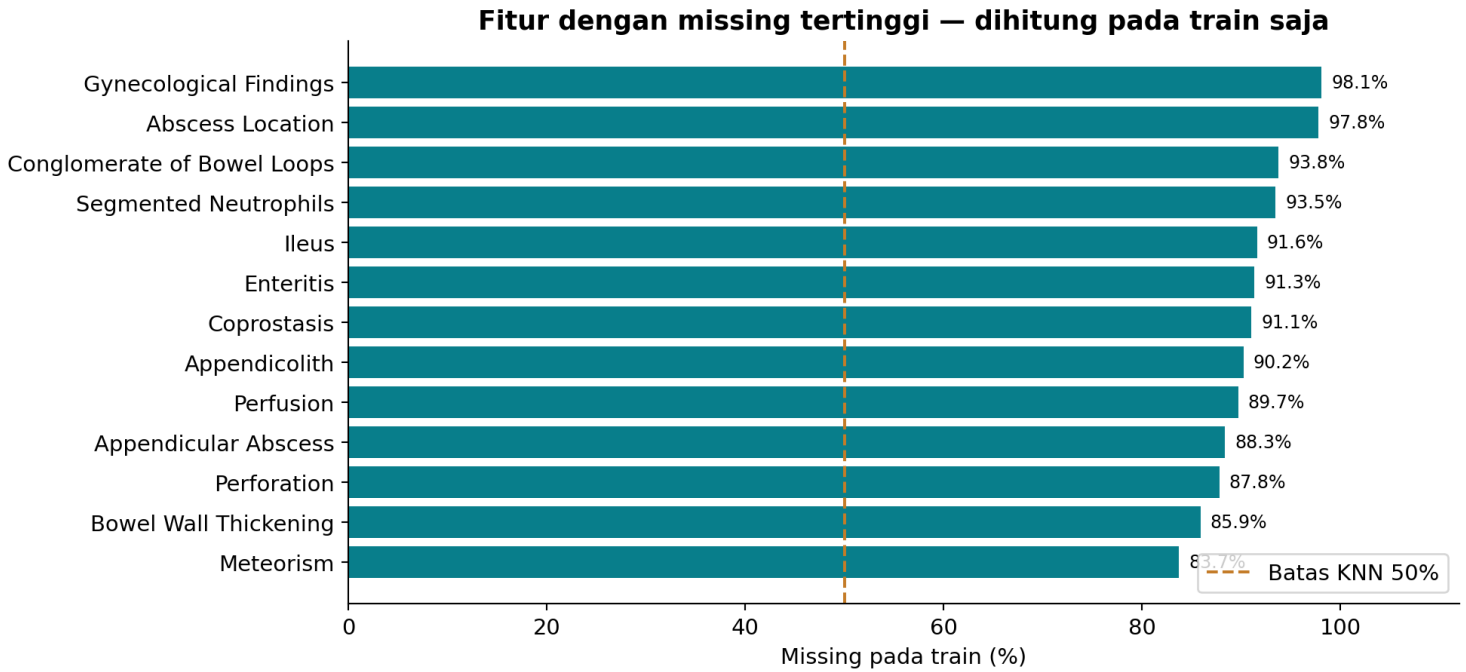
Tabular tetap 53D

17 numerik + 36 kategori

Ordinal, bukan one-hot

Tidak ada PCA/seleksi

18 fitur missing >50%



Length_of_Stay tetap disertakan pada baseline; ketersediaan pada waktu diagnosis awal belum disahkan.

Preprocessing: parameter dipelajari pada train saja

Tabular

Missing ≤50% → KNN k=5

Missing >50% → median / kategori missing

Numerik → RobustScaler

Kategori → OrdinalEncoder (unknown −1)

Validation/test: transform tersimpan

Citra

Panel → grayscale → letterbox 224×224

Skala [0,1] → tiga kanal

Normalisasi mean/std train

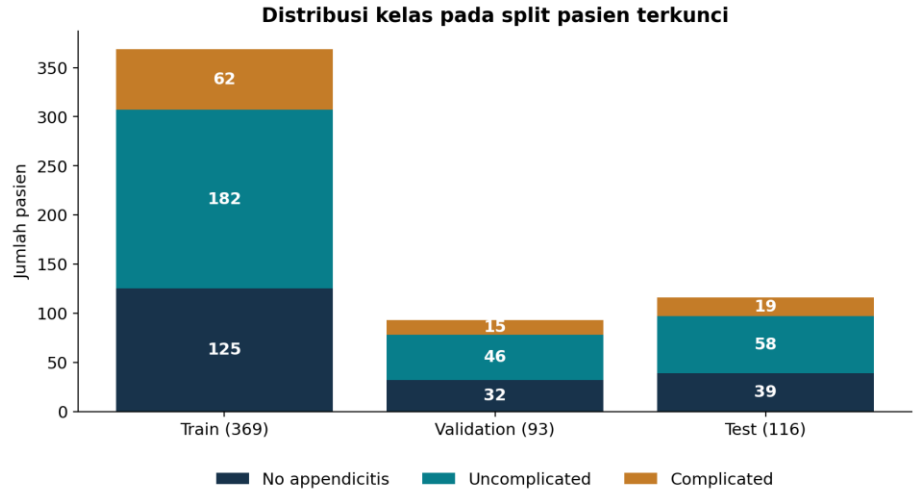
Augmentasi online hanya pada train

Validation/test: tanpa augmentasi

Panel splitting ≠ ROI anatomi appendix. Cache menyimpan uint8, augmentasi tidak menumpuk antarepoch.

Split pasien dan distribusi tiga kelas

Kelas	Train	Validation	Test	Total
No appendicitis	125 (33.88%)	32 (34.41%)	39 (33.62%)	196
Uncomplicated	182 (49.32%)	46 (49.46%)	58 (50.00%)	286
Complicated	62 (16.80%)	15 (16.13%)	19 (16.38%)	96



Citra/panel: train 1.121, validation 273, test 345. Manifest pasien digunakan kembali oleh semua kontrol.

Leakage: kontrol yang ada dan risiko yang tersisa

Kontrol terverifikasi

Patient ID terpisah antar-split

Tidak ada hash citra identik lintas split

Imputer/scaler/statistik dari train

Checkpoint dipilih dari validation

Model/optimizer baru setiap trial

Masih perlu dibatasi

Length_of_Stay untuk diagnosis awal

Waktu tersedianya temuan lanjutan

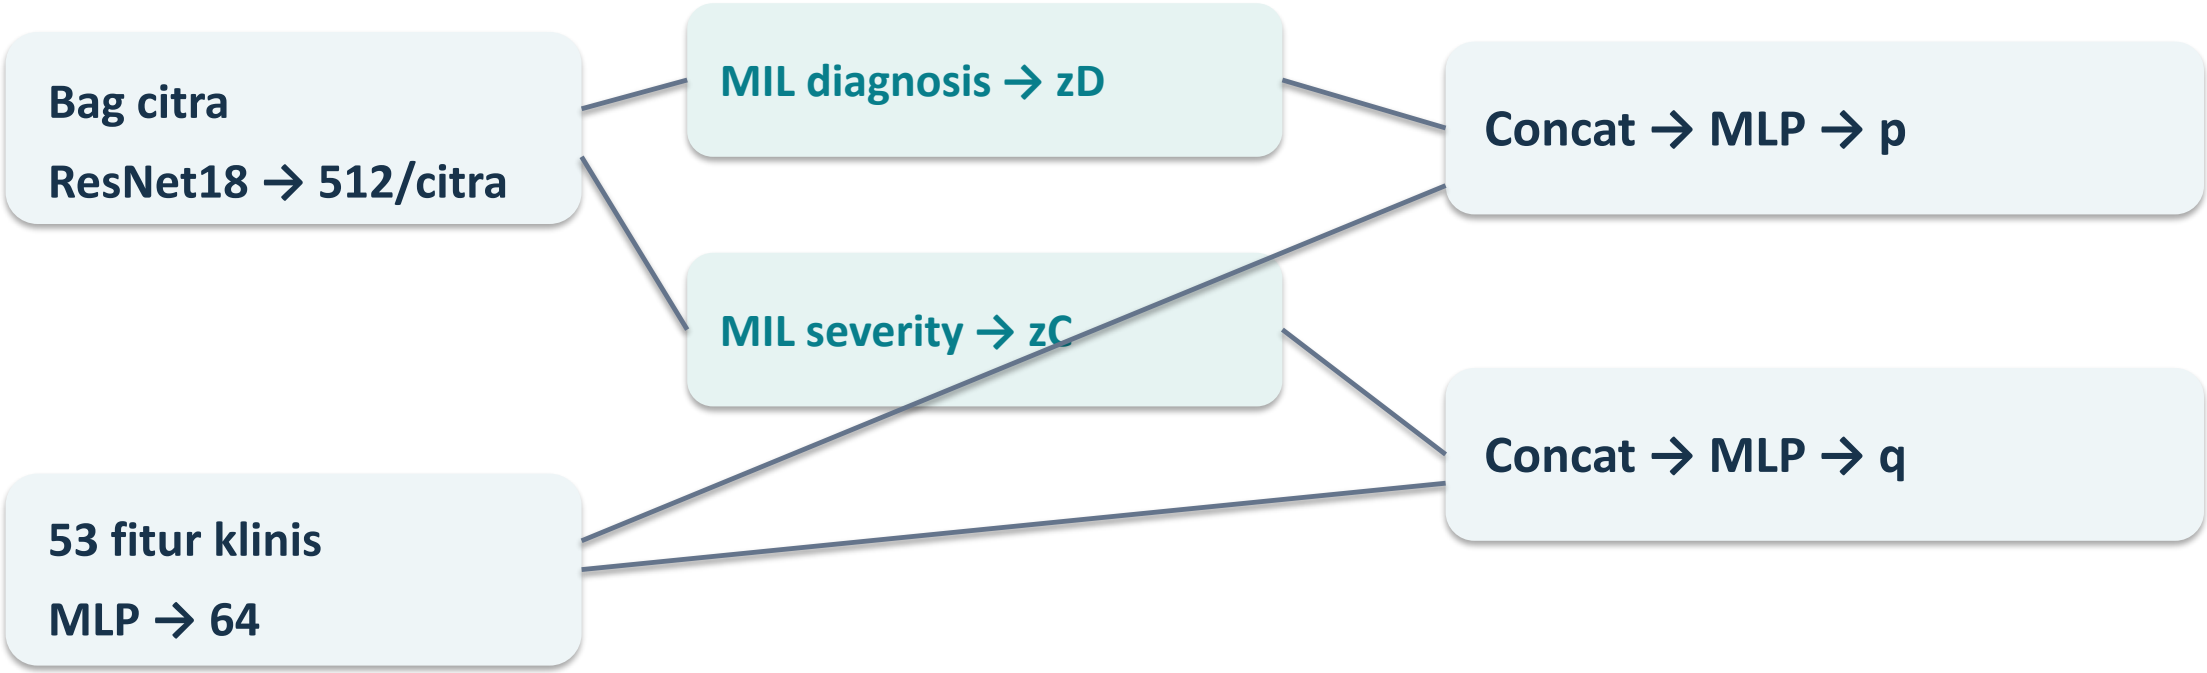
Near-duplicate tidak ditangkap hash

Satu split dan satu seed

Test telah dibaca untuk diskusi lanjutan

Kontrol split bukan bukti bahwa seluruh bentuk leakage sudah hilang.

Arsitektur: dua representasi bag, dua fusion



P(kelas) = [1−p, p(1−q), pq]

Threshold hierarkis tetap: p/q = 0,5

Frozen S26: backbone dan statistik BN tetap; attention, MLP, fusion, dan head tetap dilatih.

Search: 3 backbone × 3 optimizer × 4 profil

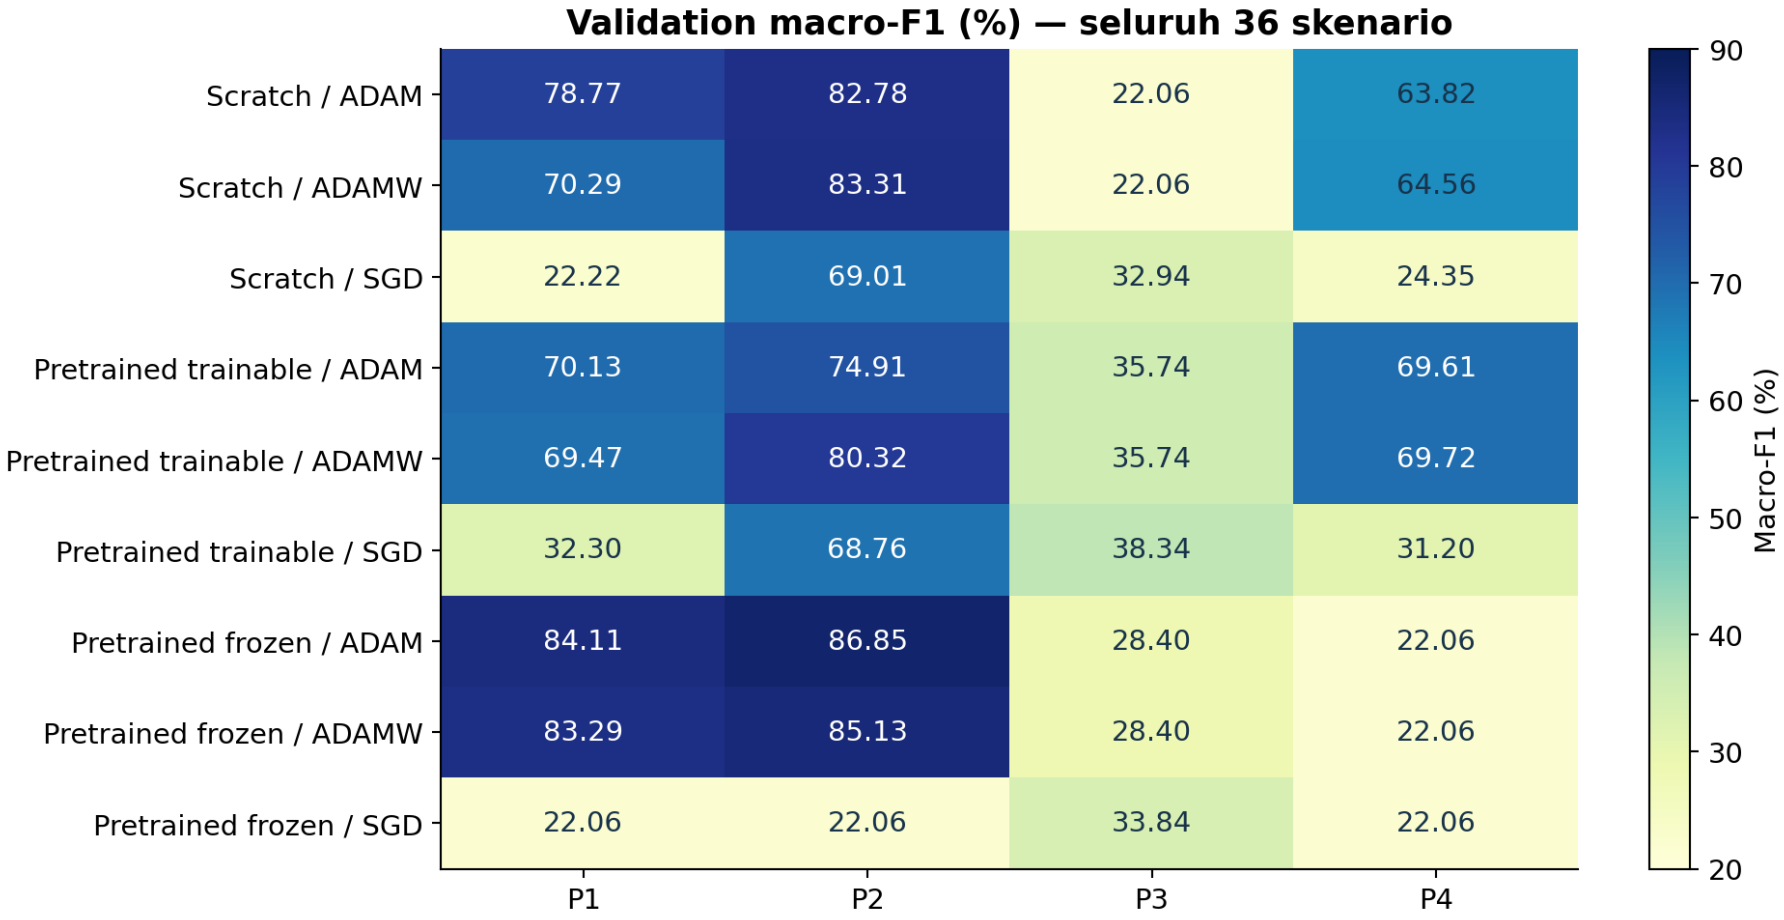
Profil	LR utama	Dropout	Weight decay
P1	1e−4	0,4	1e−3
P2	1e−3	0,2	1e−4
P3	1e−5	0,7	1e−3
P4	1e−4	0,7	1e−4

Scratch • Pretrained trainable • Pretrained frozen

Adam • AdamW • SGD | Maksimum 100 epoch | Patience 25

Checkpoint + early stopping: best validation macro-F1. Profil mengubah beberapa hyperparameter sekaligus.

Seluruh 36 hasil validation macro-F1



Semua 36 selesai. Tabel nilai lengkap terdapat pada lampiran presentasi dan laporan Word.

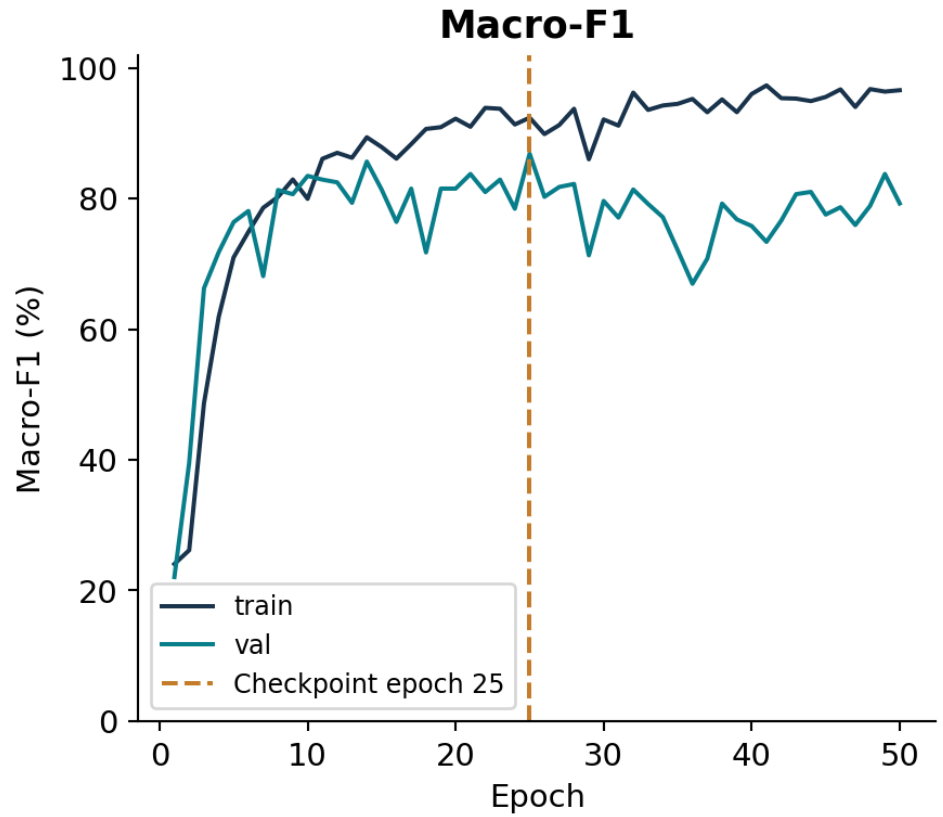
Enam konfigurasi teratas pada validation

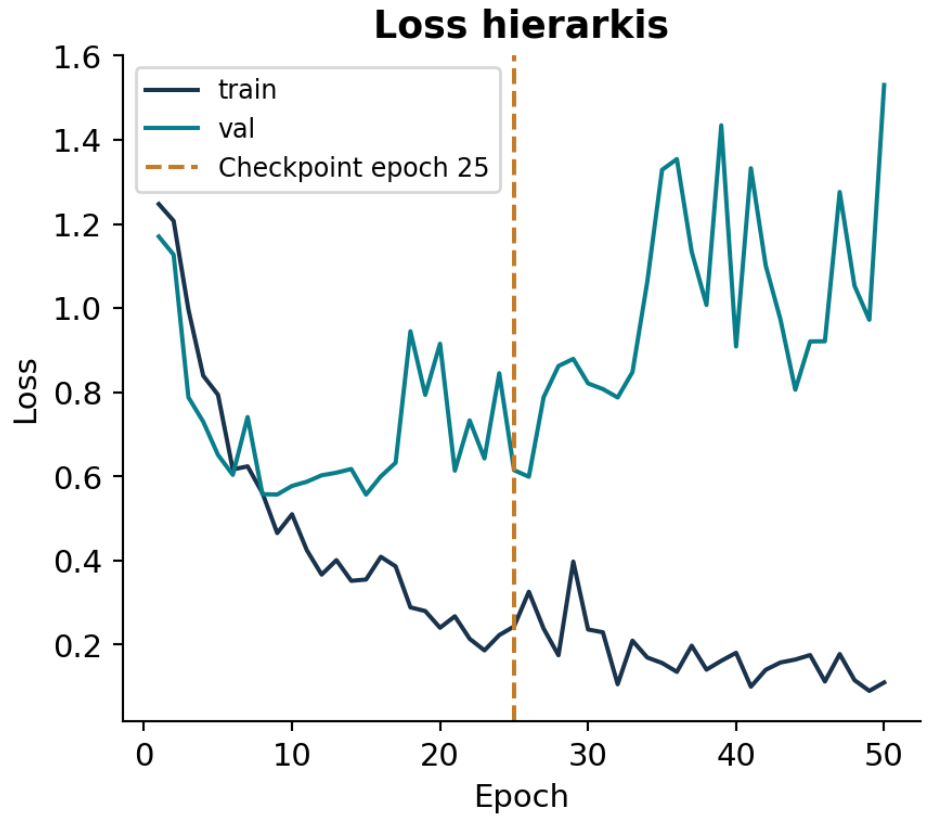
ID	Kondisi / Opt / Profil	Val Acc	Val F1	Val AUC	Gap F1
S26	PF / adam / P2	88.17	86.85	92.31	10.82
S30	PF / adamw / P2	86.02	85.13	91.38	13.23
S25	PF / adam / P1	84.95	84.11	92.63	8.87
S06	Scratch / adamw / P2	84.95	83.31	91.46	14.01
S29	PF / adamw / P1	84.95	83.29	92.97	12.65
S02	Scratch / adam / P2	84.95	82.78	92.63	9.10

S26: pretrained frozen + Adam + P2 | Checkpoint epoch 25

Skor dalam %. Gap dalam pp. PF=frozen; PT=trainable. Tabel seluruh trial ada pada lampiran.

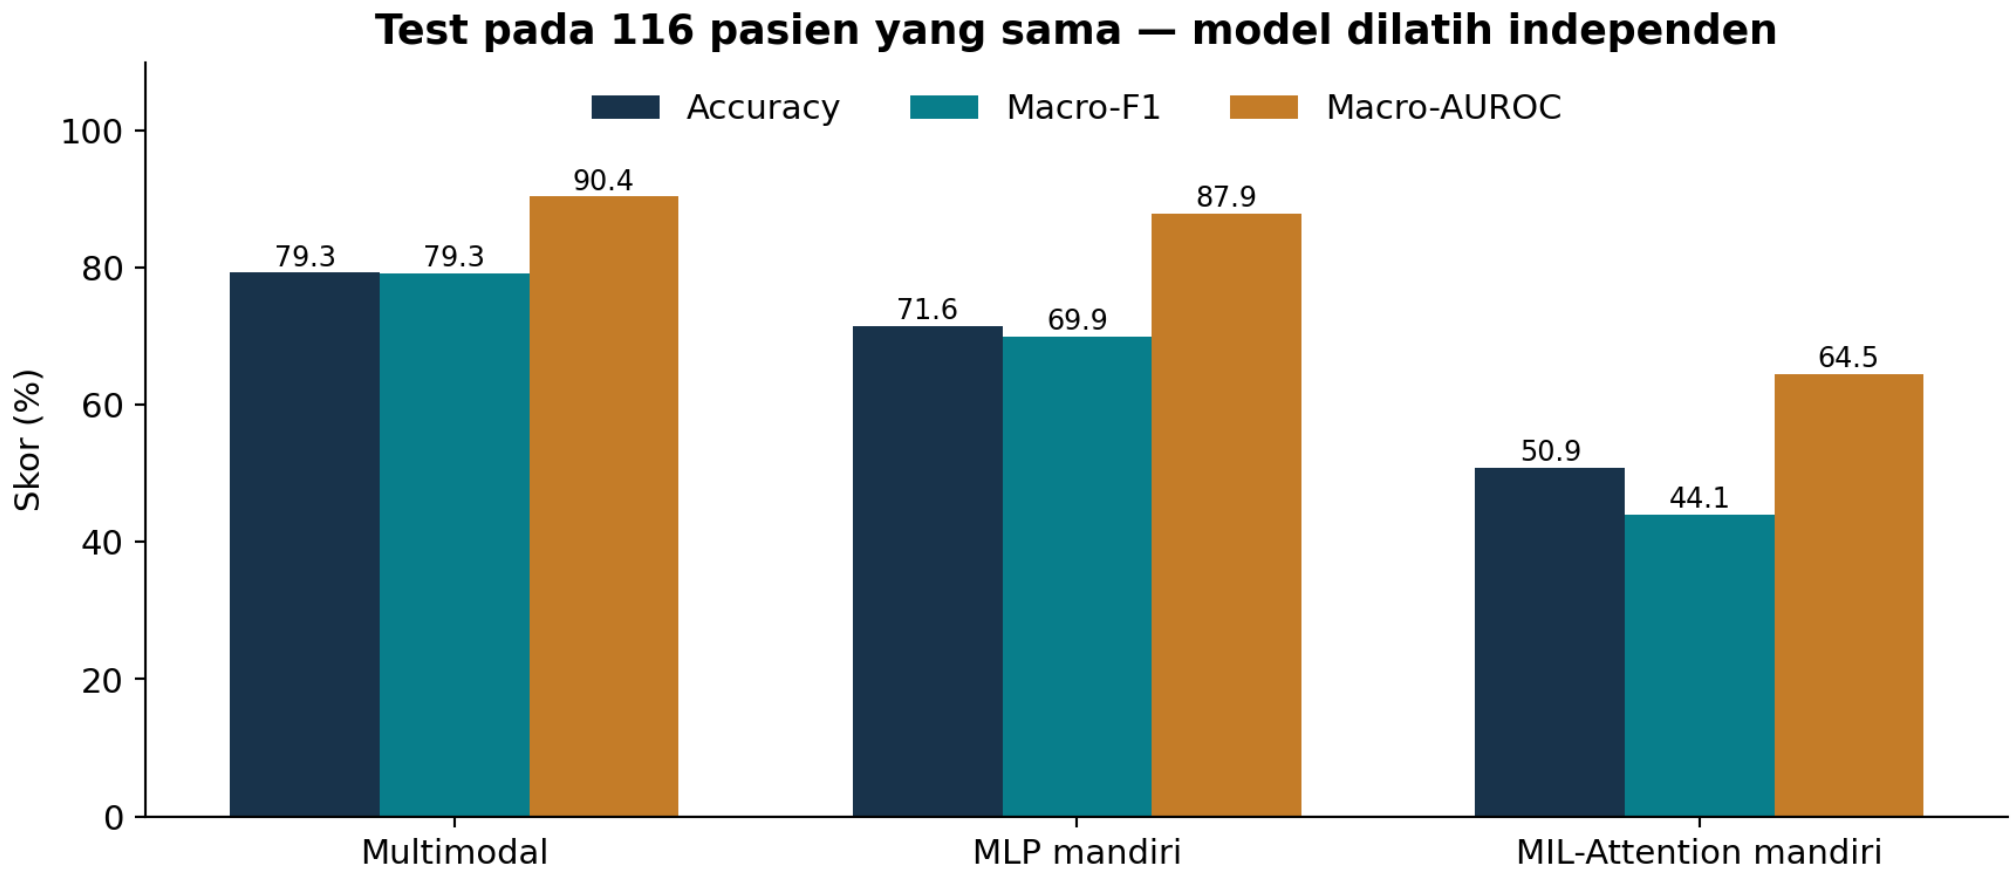
S26: kurva belajar dan checkpoint terpilih





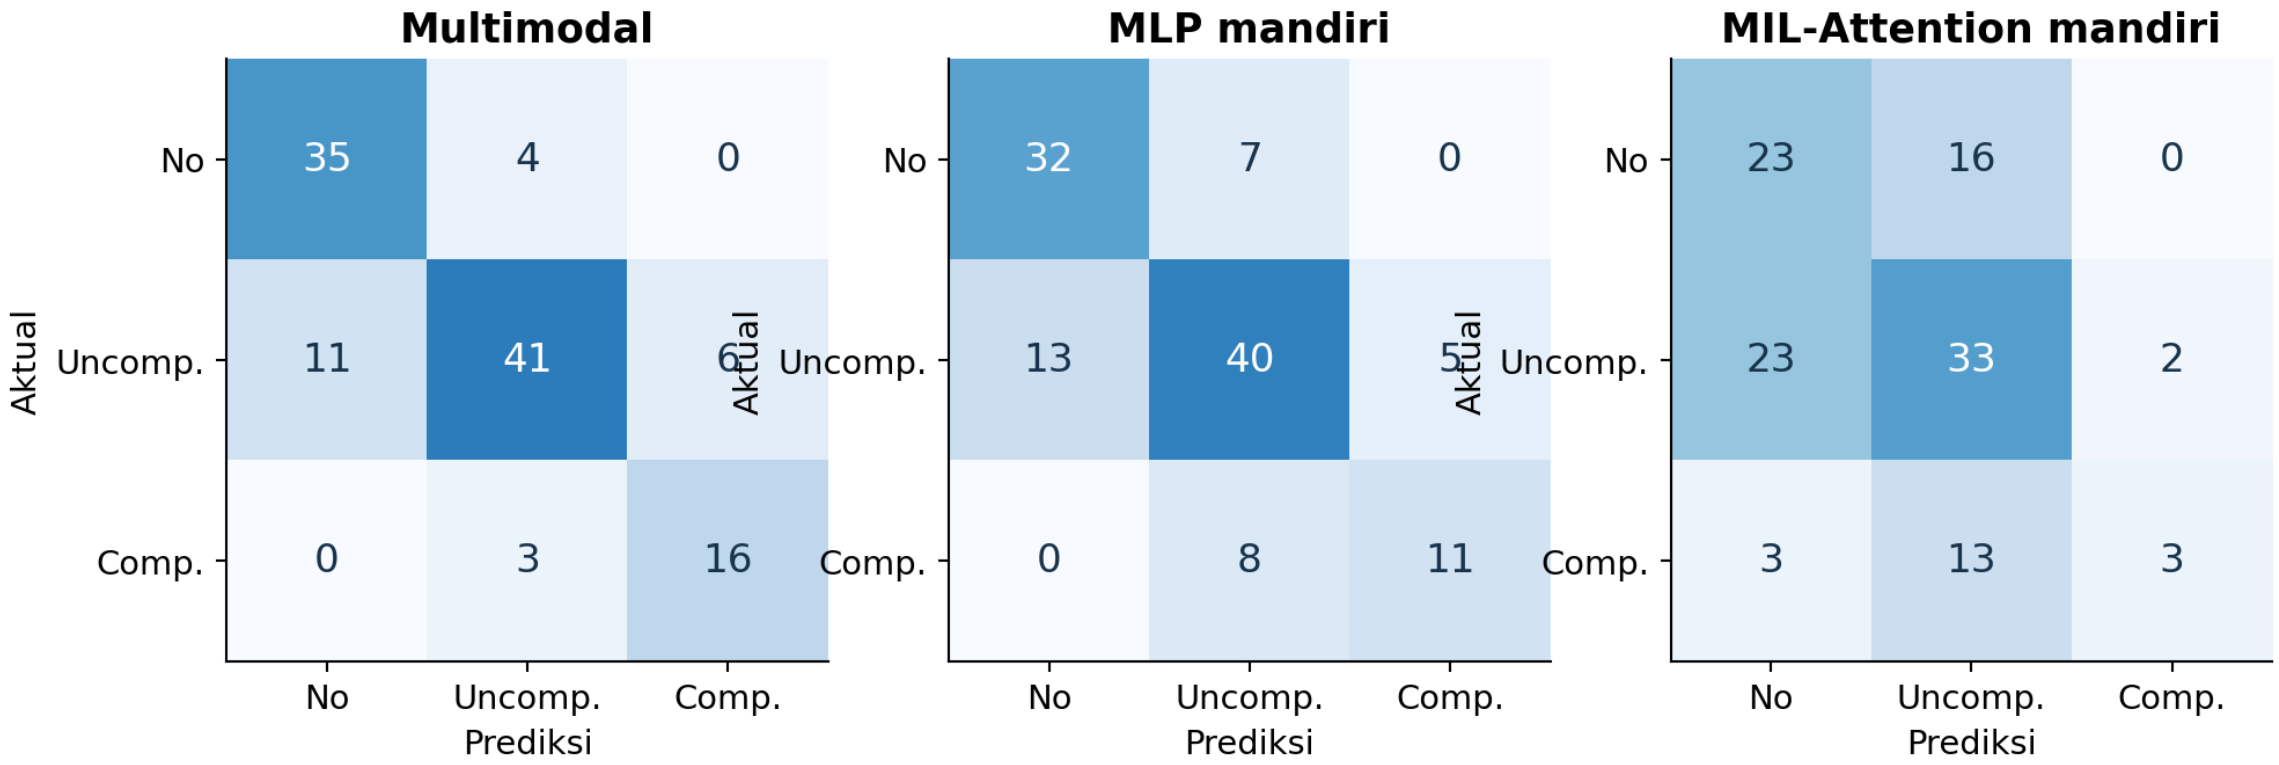
Train F1 97,68% → validation 86,85% → test 79,25%. Freeze bukan jaminan bebas overfitting.

Test tiga model: pasien sama, pelatihan berbeda



Multimodal F1 79,25% | MLP mandiri 69,95% | MIL-Attention mandiri 44,09%.

Confusion matrix: kelas mana yang tertukar?



Multimodal: recall no 89,74%, uncomplicated 70,69%, complicated 84,21%.

Diagnosis dan severity mempunyai denominator berbeda

Tugas multimodal	N	Acc %	Sens %	Spec %	F1+ %	AUC %
Diagnosis	116	87.07	85.71	89.74	89.80	93.34
Severity langsung	77	88.31	84.21	89.66	78.05	90.02
Severity setelah gating	77	88.31	84.21	89.66	78.05	90.93
Complicated end-to-end	116	92.24	84.21	93.81	78.05	93.87

Diagnosis: 11 false negative, 4 false positive

Complicated end-to-end: 3 false negative, 6 false positive

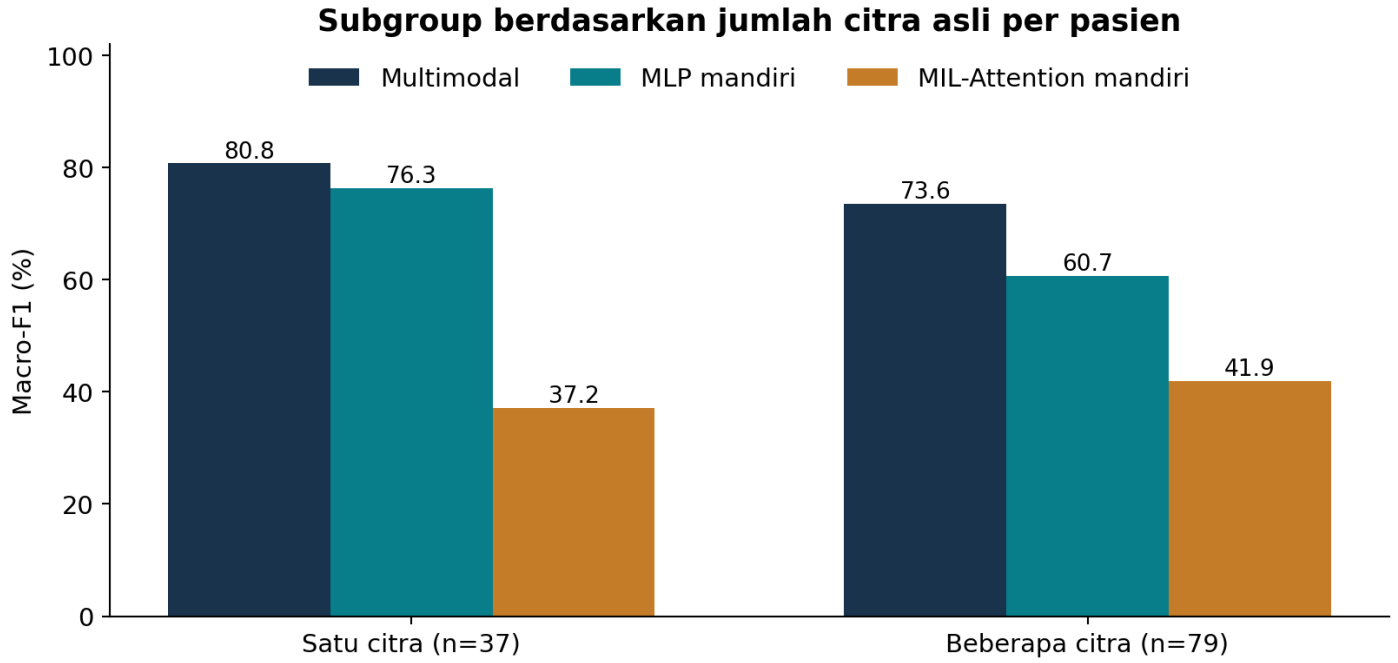
Accuracy biner tidak menggantikan accuracy/F1 tiga kelas. ROC lengkap tersedia pada Word.

Model mandiri ≠ embedding dinonaktifkan

Kondisi test	Training mandiri?	Macro-F1 %	Macro-AUC %
Multimodal lengkap	Joint training	79,25	90,41
MLP mandiri	Ya	69,95	87,90
MIL-Attention mandiri	Ya	44,09	64,49
Citra dinonaktifkan	Tidak	76,66	90,12
Klinis dinonaktifkan	Tidak	30,91	60,61

Intervensi inferensi menjawab ketergantungan model; kontrol mandiri menjawab kemampuan belajar sendiri.

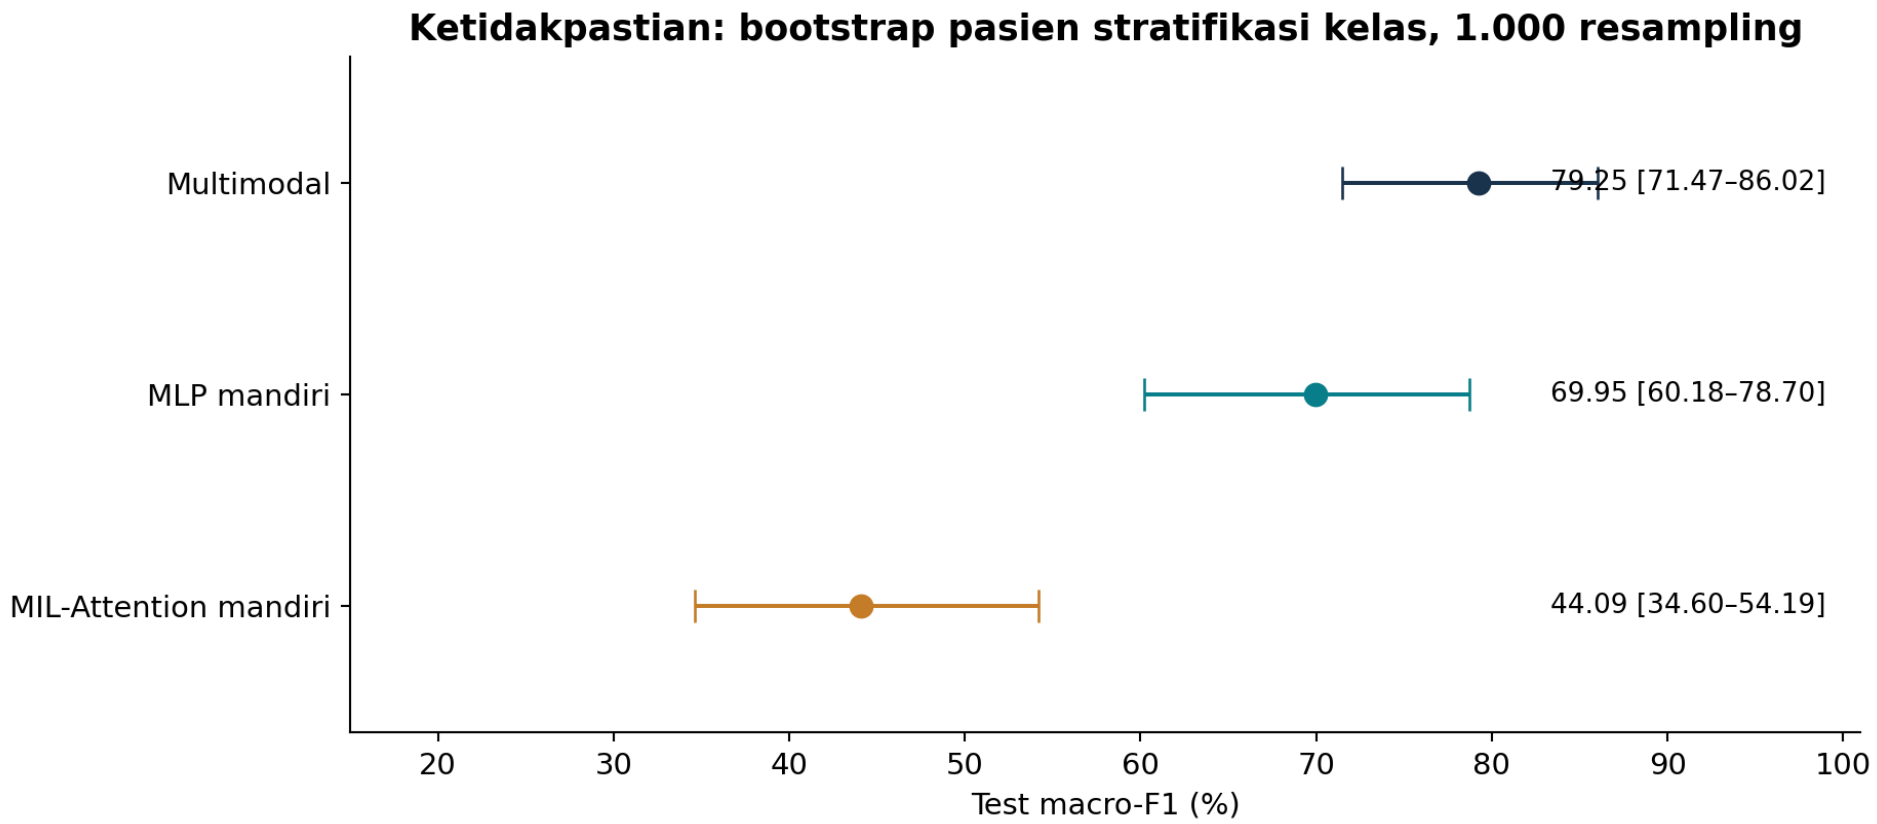
Satu citra vs beberapa citra: komposisinya berbeda



Kelompok	No	Uncomplicated	Complicated
Satu citra (37)	19	8	10
Beberapa citra (79)	20	50	9

Perbedaan subgroup bukan bukti sebab-akibat dari jumlah citra atau mekanisme attention.

Ketidakpastian hasil: satu split, satu seed



CI tidak mencakup variasi seed, split, hyperparameter search, atau populasi eksternal.

Marcinkevičs [2]: diagnosis

Model	N / rekaman	AUROC %	AUPR paper %	AP lokal %	PR-trap %
MVBM-avg	Paper: 10 init.	76.00 ± 5.00	89.00 ± 4.00	—	—
MVBM-LSTM	Paper: 10 init.	76.00 ± 4.00	91.00 ± 2.00	—	—
SSMVCBM-avg	Paper: 10 init.	80.00 ± 3.00	92.00 ± 2.00	—	—
SSMVCBM-LSTM	Paper: 10 init.	80.00 ± 6.00	92.00 ± 4.00	—	—
Hierarkis S26	116	93.34	—	97.00	96.99
Tanpa training ulang	116	93.34	—	97.00	96.99
Binary dilatih ulang	116	94.71	—	97.69	97.68
Softmax marginal	116	94.11	—	97.52	97.51

Paper: mean±SD, 10 inisialisasi. Lokal: 1 seed, test 116. Semua model lokal sudah diuji; — = metrik tidak tersedia/tidak sepadan.

Marcinkevičs [2]: severity seluruh pasien

Model	N / rekaman	AUROC %	AUPR paper %	AP lokal %	PR-trap %
MVBM-avg	Paper: 10 init.	71.00 ± 12.00	59.00 ± 11.00	—	—
MVBM-LSTM	Paper: 10 init.	74.00 ± 13.00	58.00 ± 12.00	—	—
SSMVCBM-avg	Paper: 10 init.	73.00 ± 7.00	57.00 ± 9.00	—	—
SSMVCBM-LSTM	Paper: 10 init.	78.00 ± 5.00	58.00 ± 10.00	—	—
Hierarkis S26	116	93.87	—	80.83	80.26
Tanpa training ulang	116	93.87	—	80.83	80.26
Binary dilatih ulang	116	94.03	—	83.64	83.28
Softmax marginal	116	96.74	—	86.53	86.19

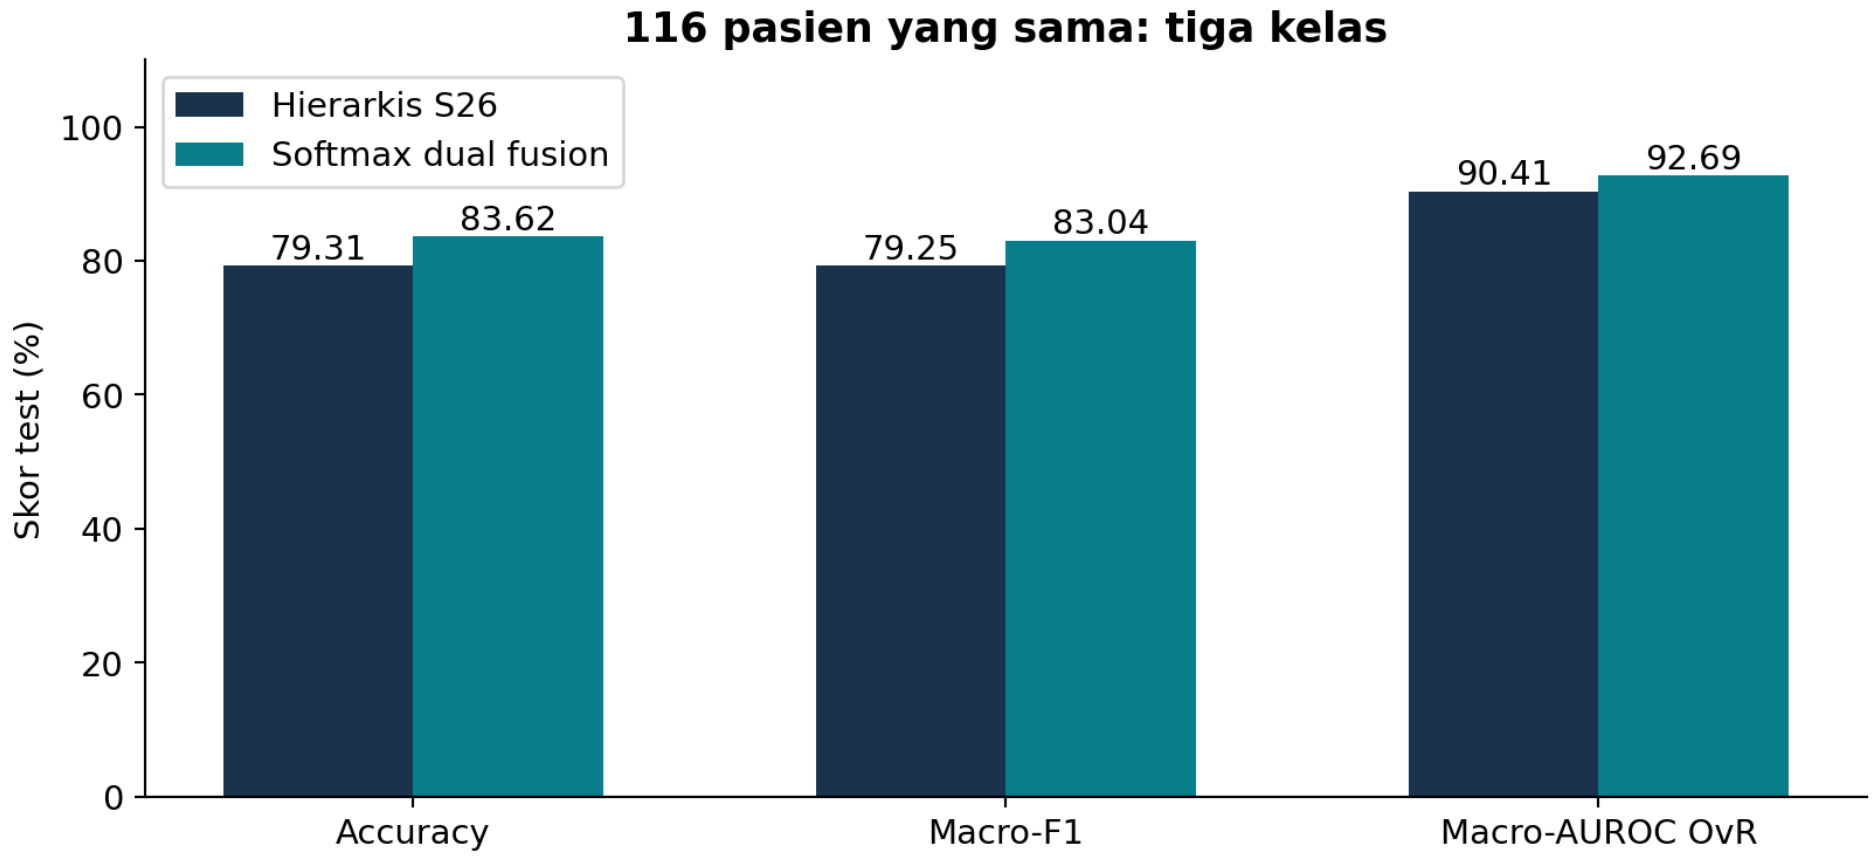
Paper: mean±SD, 10 inisialisasi. Lokal: 1 seed, test 116. Semua model lokal sudah diuji; — = metrik tidak tersedia/tidak sepadan.

Barthwal [1]: perbandingan diagnosis biner

Model	Acc %	Prec %	Sens %	Spec %	F1+ %	AUC %
Paper [1]	97.30	96.50	97.80	96.20	97.10	96.80
Hierarkis S26	87.07	94.29	85.71	89.74	89.80	93.34
Tanpa training ulang	87.07	94.29	85.71	89.74	89.80	93.34
Binary dilatih ulang	88.79	94.44	88.31	89.74	91.28	94.71
Softmax marginal	90.52	94.59	90.91	89.74	92.72	94.11

F1 positif diagnosis, bukan macro-F1 tiga kelas. Paper berbeda cohort/protokol; tanpa training ulang identik dengan p S26.

Kontrol tiga kelas: softmax versus hierarkis



Test tiga kelas memakai argmax softmax. Head/loss berubah; belum ada pengujian stabilitas multiseed.

Pertanyaan yang diputuskan peneliti

Pertanyaan	Bukti yang tersedia
Kapan prediksi akan digunakan?	Length_of_Stay dan temuan lanjutan masih pada baseline.
Apa batas utama cabang citra?	MIL mandiri rendah; backbone/ROI/optimasi belum diisolasi.
Apakah attention lebih baik dari pooling lain?	Belum ada kontrol mean/LSTM yang setara pada run aktif.
Apakah fusion encoder independen layak diuji?	Checkpoint mandiri tersedia; hasil fusion tahap kedua belum ada.
Bukti apa yang dibutuhkan untuk klaim akhir?	Stabilitas multiseed, protokol terkunci, evaluasi independen.

Penjelasan mekanistik di Word diberi batas sebagai hipotesis, bukan penyebab yang sudah terkonfirmasi.

Referensi utama dan lokasi data pendukung

[1] Barthwal et al. (2026) — preprocessing dan multimodal referensi

[2] Marcinkevičs et al. (2024), Medical Image Analysis — multiview CBM

[3] Ilse et al. (2018), ICML — gated attention-MIL

[4] Kapoor & Narayanan (2023), Patterns — leakage dan reproducibility

[5] Patterns (2024), 100994 — interpretasi ROC pada imbalance

Word: penjelasan rinci + 53 fitur + 36 trial

Folder tables/: angka lengkap dan sumber yang dapat ditelusuri

Lampiran: validasi rank 1–12

Rank	ID	Kondisi/opt/P	Epoch	Acc %	F1 %	AUC %	Loss
1	S26	PF/adam/P2	25	88.17	86.85	92.31	0.615
2	S30	PF/adamw/P2	25	86.02	85.13	91.38	0.675
3	S25	PF/adam/P1	76	84.95	84.11	92.63	0.528
4	S06	S/adamw/P2	26	84.95	83.31	91.46	0.741
5	S29	PF/adamw/P1	97	84.95	83.29	92.97	0.563
6	S02	S/adam/P2	12	84.95	82.78	92.63	0.591
7	S18	PT/adamw/P2	49	80.65	80.32	89.58	1.291
8	S01	S/adam/P1	89	79.57	78.77	89.23	0.902
9	S14	PT/adam/P2	21	75.27	74.91	88.86	1.353
10	S05	S/adamw/P1	51	69.89	70.29	85.61	1.082
11	S13	PT/adam/P1	28	69.89	70.13	84.55	0.938
12	S20	PT/adamw/P4	57	68.82	69.72	80.28	1.365

PF=pretrained frozen; PT=pretrained trainable; S=scratch. P1–P4 lihat slide rancangan search.

Lampiran: validasi rank 13–24

Rank	ID	Kondisi/opt/P	Epoch	Acc %	F1 %	AUC %	Loss
13	S16	PT/adam/P4	50	68.82	69.61	81.10	1.146
14	S17	PT/adamw/P1	27	68.82	69.47	84.53	0.896
15	S10	S/sgd/P2	94	67.74	69.01	82.27	0.790
16	S22	PT/sgd/P2	82	67.74	68.76	80.75	1.075
17	S08	S/adamw/P4	56	64.52	64.56	79.78	0.908
18	S04	S/adam/P4	62	64.52	63.82	76.60	1.230
19	S23	PT/sgd/P3	1	47.31	38.34	58.25	1.373
20	S19	PT/adamw/P3	1	51.61	35.74	57.71	1.358
21	S15	PT/adam/P3	1	51.61	35.74	57.82	1.358
22	S35	PF/sgd/P3	4	50.54	33.84	53.53	1.364
23	S11	S/sgd/P3	6	46.24	32.94	48.05	1.380
24	S21	PT/sgd/P1	1	50.54	32.30	57.59	1.358

PF=pretrained frozen; PT=pretrained trainable; S=scratch. P1–P4 lihat slide rancangan search.

Lampiran: validasi rank 25–36

Rank	ID	Kondisi/opt/P	Epoch	Acc %	F1 %	AUC %	Loss
25	S24	PT/sgd/P4	1	48.39	31.20	57.30	1.359
26	S31	PF/adamw/P3	1	49.46	28.40	54.19	1.359
27	S27	PF/adam/P3	1	49.46	28.40	54.19	1.359
28	S12	S/sgd/P4	2	50.54	24.35	48.71	1.361
29	S09	S/sgd/P1	2	49.46	22.22	49.36	1.357
30	S34	PF/sgd/P2	25	49.46	22.06	61.74	1.152
31	S07	S/adamw/P3	27	49.46	22.06	58.96	1.160
32	S03	S/adam/P3	27	49.46	22.06	58.51	1.161
33	S32	PF/adamw/P4	26	49.46	22.06	67.88	1.174
34	S28	PF/adam/P4	26	49.46	22.06	67.91	1.176
35	S33	PF/sgd/P1	26	49.46	22.06	48.27	1.202
36	S36	PF/sgd/P4	26	49.46	22.06	49.23	1.216

PF=pretrained frozen; PT=pretrained trainable; S=scratch. P1–P4 lihat slide rancangan search.